

Atividade Prática 1 - Implementação K-Means em Python

Nathan Mateus de Lima e Vítor Oliveira Amorim

17 de agosto de 2026

Introdução

Nesta atividade, foi implementado o algoritmo **K-Means**, um dos algoritmos de aprendizado não supervisionado mais populares para a tarefa de clusterização.

Implementação

A implementação do algoritmo foi feita em linguagem Python, sem o auxílio de bibliotecas externas. As estruturas principais foram manipuladas em 3 classes dedicadas: `'KMeans'`, para o algoritmo K-Means, `'Point'`, para cada um dos objetos a serem clusterizados, e `'Cluster'`, para cada um dos K clusters do algoritmo.

Testes Realizados

A fim de validar os resultados obtidos, foram realizados testes com os arquivos de entrada fornecidos para a atividade: "dados_1_simples.csv", "dados_2_3clusters.csv", "dados_3_3d.csv" e "dados_5_4d_120entradas.csv".

Os resultados obtidos para cada um dos conjuntos de dados de entrada foram comparados aos resultados da implementação do K-Means da biblioteca *scikit-learn*.

Resultados

Dataset: dados_1_simples.csv

Saída:

```
1 =====
2                               Dados 1
3 =====
4 cluster 0:
5 (5.0,8.0)
6 (8.0,8.0)
7 (9.0,11.0)
8 (8.0,9.0)
9 (9.0,10.0)
10
```

```

11 centroid: [7.8, 9.2]
12
13 cluster 1:
14 (1.0,2.0)
15 (1.5,1.8)
16 (1.2,0.8)
17 (1.0,0.6)
18 (2.0,0.9)
19
20 centroid: [1.34, 1.22]

```

Dataset: dados 2_3clusters.csv

Saída:

```

1  =====
2                                Dados 2
3  =====
4 cluster 0:
5 (90.0,10.0)
6 (92.0,11.0)
7 (89.0,9.0)
8 (91.0,12.0)
9
10 centroid: [90.5, 10.5]
11
12 cluster 1:
13 (50.0,50.0)
14 (52.0,48.0)
15 (49.0,51.0)
16 (51.5,49.5)
17
18 centroid: [50.625, 49.625]
19
20 cluster 2:
21 (10.0,10.0)
22 (11.0,12.0)
23 (9.5,11.5)
24 (10.5,9.0)
25
26 centroid: [10.25, 10.625]

```

Dataset: dados_3_3d.csv

Saída:

```

1  =====
2                                Dados 3
3  =====
4 cluster 0:
5 (10.0,10.0,10.0)
6 (10.5,9.8,10.2)
7 (9.9,10.1,9.7)
8 (10.2,10.3,10.1)
9
10 centroid: [10.149999999999999, 10.05, 10.0]
11

```

```

12 cluster 1:
13 (1.0,1.0,1.0)
14 (1.5,2.0,1.2)
15 (1.1,1.3,0.9)
16 (1.2,1.1,1.4)
17
18 centroid: [1.2, 1.35, 1.125]

```

Dataset: dados_5_4d_120entradas.csv

Saída:

```

1  =====
2                                Dados 4
3  =====
4 cluster 0:
5 (80.18,82.77,15.4,17.82)
6 (81.59,85.01,19.11,20.51)
7 (82.46,82.65,14.78,20.58)
8 (83.14,81.97,16.78,21.06)
9 (82.76,86.28,15.09,19.06)
10 (77.75,85.35,14.65,23.64)
11 (78.9,85.58,12.18,19.29)
12 (80.47,86.48,17.61,19.92)
13 (77.99,85.82,15.93,20.88)
14 (78.74,87.04,15.16,21.26)
15 (82.29,86.1,15.52,23.88)
16 (80.44,84.47,15.2,22.67)
17 (80.21,85.93,17.15,19.08)
18 (76.89,85.54,15.41,18.91)
19 (81.57,86.09,13.21,20.93)
20 (79.65,82.33,15.82,19.92)
21 (78.66,85.94,15.88,18.96)
22 (80.72,86.83,13.72,20.69)
23 (80.0,89.08,11.65,21.25)
24 (79.45,84.82,18.42,19.98)
25 (84.03,84.2,15.63,19.12)
26 (78.76,85.11,14.49,20.36)
27 (76.21,88.6,14.7,23.14)
28 (78.19,85.53,20.7,18.43)
29 (77.31,84.02,15.85,21.25)
30 (82.32,84.54,12.12,19.22)
31 (82.23,85.84,11.48,19.94)
32 (82.52,88.83,16.01,20.56)
33 (77.77,83.48,15.08,20.91)
34 (81.04,84.14,12.93,18.6)
35
36 centroid: [80.14133333333334, 85.34566666666665, 15.255333333333335,
37           20.394000000000002]
38
39 cluster 1:
40 (9.74,14.69,11.8,9.26)
41 (9.77,12.3,12.6,7.52)
42 (9.61,15.21,12.42,10.09)
43 (11.18,15.2,10.67,6.17)
44 (10.44,17.36,12.07,7.81)
45 (10.96,12.38,11.44,8.88)
46 (11.57,14.57,12.68,8.45)

```

```
46 (11.41,13.0,13.02,5.27)
47 (5.28,13.91,10.35,9.58)
48 (11.2,12.81,13.53,6.2)
49 (9.84,14.47,12.21,9.47)
50 (11.15,15.63,13.17,8.86)
51 (8.87,13.71,11.15,8.9)
52 (9.55,19.2,10.53,6.02)
53 (11.38,17.56,12.91,9.5)
54 (12.57,14.83,9.44,7.04)
55 (11.72,12.4,12.06,8.46)
56 (9.43,16.3,13.05,12.18)
57 (11.12,13.9,10.99,6.5)
58 (11.71,13.98,11.87,9.35)
59 (8.7,14.47,8.69,6.05)
60 (8.98,15.75,14.15,7.97)
61 (10.47,15.3,13.95,9.61)
62 (10.49,13.18,13.63,8.69)
63 (12.21,14.95,15.52,7.35)
64 (12.87,15.21,11.07,5.97)
65 (9.73,17.56,13.47,9.24)
66 (5.72,16.28,13.0,7.01)
67 (8.87,15.0,15.1,6.1)
68 (9.23,17.45,11.2,7.34)
69
70 centroid: [10.192333333333336, 14.952, 12.258000000000001, 8.028]
71
72 cluster 2:
73 (49.79,18.45,88.31,93.67)
74 (48.23,21.56,89.92,97.83)
75 (54.1,20.04,87.21,94.31)
76 (49.86,17.32,89.55,95.52)
77 (49.17,18.62,88.63,98.22)
78 (49.71,18.51,89.33,96.72)
79 (48.77,20.87,91.31,96.35)
80 (52.52,19.01,92.04,93.57)
81 (49.29,22.15,91.48,95.0)
82 (47.86,21.01,88.87,93.34)
83 (48.83,20.44,86.18,95.65)
84 (50.31,18.95,91.87,96.1)
85 (48.91,18.79,91.25,92.27)
86 (49.4,18.86,90.13,95.38)
87 (50.07,22.04,90.41,94.43)
88 (47.82,21.3,90.95,97.61)
89 (48.65,20.05,89.89,94.84)
90 (50.02,16.91,91.48,96.18)
91 (52.03,24.05,89.43,94.93)
92 (50.02,23.5,86.88,95.87)
93 (47.35,15.35,86.36,92.51)
94 (51.92,18.44,89.59,92.91)
95 (51.1,18.02,92.37,93.21)
96 (48.62,20.22,90.04,97.56)
97 (50.22,17.83,88.99,93.97)
98 (51.31,20.69,89.79,96.57)
99 (49.05,19.75,90.33,97.75)
100 (49.82,19.37,88.12,96.23)
101 (48.94,20.62,86.58,96.88)
102 (47.6,18.6,91.91,92.6)
103
```

```
104 centroid: [49.70966666666666, 19.71066666666667, 89.63999999999997,  
105           95.266]  
106 cluster 3:  
107 (17.92,76.16,75.84,24.4)  
108 (20.81,77.74,80.13,26.8)  
109 (19.28,73.66,78.79,27.75)  
110 (21.79,75.88,85.99,24.94)  
111 (21.12,75.55,79.6,29.17)  
112 (22.71,72.48,79.28,25.77)  
113 (21.41,72.57,75.94,21.57)  
114 (19.87,74.81,80.62,23.61)  
115 (17.8,71.36,80.59,25.67)  
116 (21.79,76.42,79.66,27.43)  
117 (19.75,73.81,79.06,23.95)  
118 (16.1,75.28,80.45,24.35)  
119 (18.72,75.67,83.09,25.07)  
120 (19.09,73.94,79.87,22.72)  
121 (19.77,75.11,83.32,26.7)  
122 (21.86,73.72,81.21,22.95)  
123 (20.56,75.75,78.62,28.6)  
124 (21.02,71.58,81.0,24.27)  
125 (20.0,75.84,80.7,21.33)  
126 (17.92,76.39,82.34,28.43)  
127 (23.25,71.3,81.39,21.55)  
128 (22.9,75.46,77.95,28.62)  
129 (21.16,71.6,80.53,23.68)  
130 (20.2,74.16,82.47,22.44)  
131 (20.57,78.27,78.51,25.38)  
132 (20.36,73.76,81.17,25.17)  
133 (18.3,78.17,81.42,24.7)  
134 (18.85,73.59,82.22,24.74)  
135 (20.83,74.67,81.11,24.79)  
136 (21.37,74.67,81.49,26.21)  
137  
138 centroid: [20.236, 74.64566666666666, 80.47866666666665, 25.092]
```

Dificuldades Encontradas

No geral, não tivemos grandes dificuldades, com exceção de dúvidas pontuais de implementação em linguagem Python, como métodos que permitem facilitar o processo de implementação.

Na primeira versão de nossa implementação, todos os pontos estavam sendo agrupados em um único cluster, apesar de utilizarmos um valor de $K > 1$. Após uma breve sessão de *debug*, conseguimos identificar o erro de lógica e corrigi-lo de forma que o algoritmo funcionasse como o esperado.